INTELIGÊNCIA ARTIFICIAL · ETAPA 01

# Análise exploratória e diagnóstico dos dados

Detecção de intrusão em redes — Base NSL-KDD

**Professora:** Cristiane Neri Nobre
**Integrantes:** Gabriel Ferreira Pereira; Gabriel Matos Nogueira;
Daniel Santos Garcia; Daniel Rocha de Souza; Rafael Henrique Silva.

**Notebook:** acessar o código e as análises no Google Colab.

## 1. Objetivo e caracterização da base

Esta etapa caracteriza os dados da competição e identifica problemas que orientarão o pré-processamento. A análise utiliza exclusivamente **treino.csv**, com **69.833 registros e 50 colunas**: 49 atributos descritivos e a classe. No notebook, **class** foi renomeada para **target**, preservando os valores **normal** e **anomaly**.

O arquivo contém os 41 atributos tradicionais da NSL-KDD e oito colunas adicionais: src_bytes_kb, dst_bytes_kb, total_bytes, same_srv_pct, protocolo_cod, score_ids_legado, tipo_alerta_soc e tempo_resposta_analista_min. As verificações desta etapa preservam os dados originais.

## 2. Classes e desbalanceamento

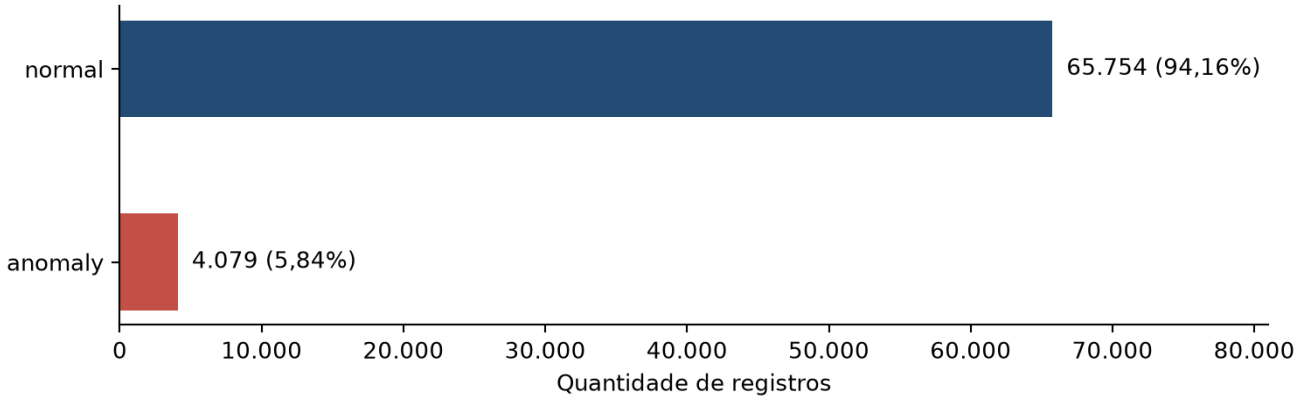



Figura 1. Distribuição das classes no conjunto de treino.

Há cerca de **16,1 conexões normais por anomalia**. Prever todas as conexões como normais produziria 94,16% de acurácia, sem detectar qualquer anomalia. Isso reforça o uso do **F1 macro**, métrica oficial, e de precisão e recall por classe. O balanceamento será comparado nas próximas etapas, somente dentro das partições de treino da validação.

# Categorias e dados ausentes

## 3. Atributos categóricos e diferenças de formatação

Foram identificados quatro atributos textuais. A comparação com uma versão auxiliar padronizada revelou diferenças entre maiúsculas e minúsculas e espaços nas categorias. A base original foi preservada.

| Atributo | Categorias originais | Após padronização |
|---|---|---|
| protocol_type | 6 | 3 |
| service | 96 | 67 |
| flag | 19 | 11 |
| tipo_alerta_soc | 2 | 2 |

Tabela 1. Quantidades de categorias distintas, desconsiderando ausências.

**service** apresenta a maior cardinalidade: 67 categorias após a padronização. A escolha da codificação deverá considerar suas frequências e o aumento no número de atributos. Atribuir códigos inteiros aos serviços pode introduzir uma ordem artificial.

Atributos numéricos com poucos valores distintos também foram inspecionados. Contagens como num_failed_logins e num_shells continuam sendo quantitativas discretas; poucos valores não definem, por si só, uma variável categórica.

## 4. Valores ausentes

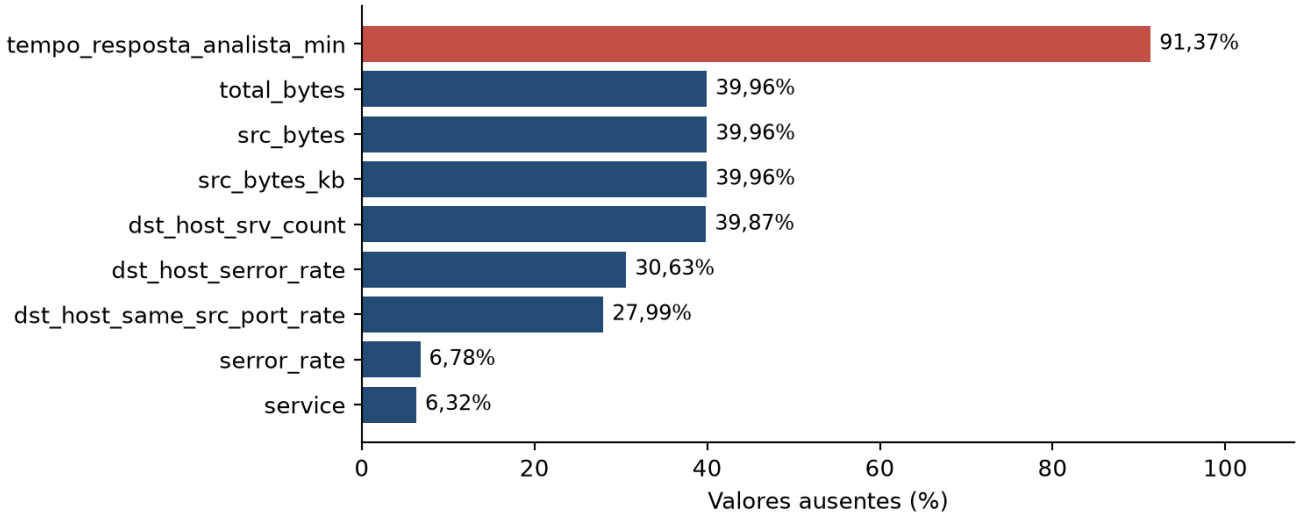



Figura 2. Nove atributos com maior percentual de valores ausentes.

**src_bytes** possui 27.906 ausências (39,96%). Em **tempo_resposta_analista_min**, são 63.804 (91,37%). O tratamento deve considerar a natureza de cada variável e a origem das ausências. Nesse último atributo, o próprio padrão de preenchimento também será investigado como possível informação relacionada à classe.

# Inconsistências e redundâncias

## 5. Violações de domínio

Foram encontrados **358 registros com duration negativo** e **189 com src_bytes negativo**, incompatíveis com duração e quantidade de bytes. Cinco atributos de taxa possuem valores fora de [0, 1].

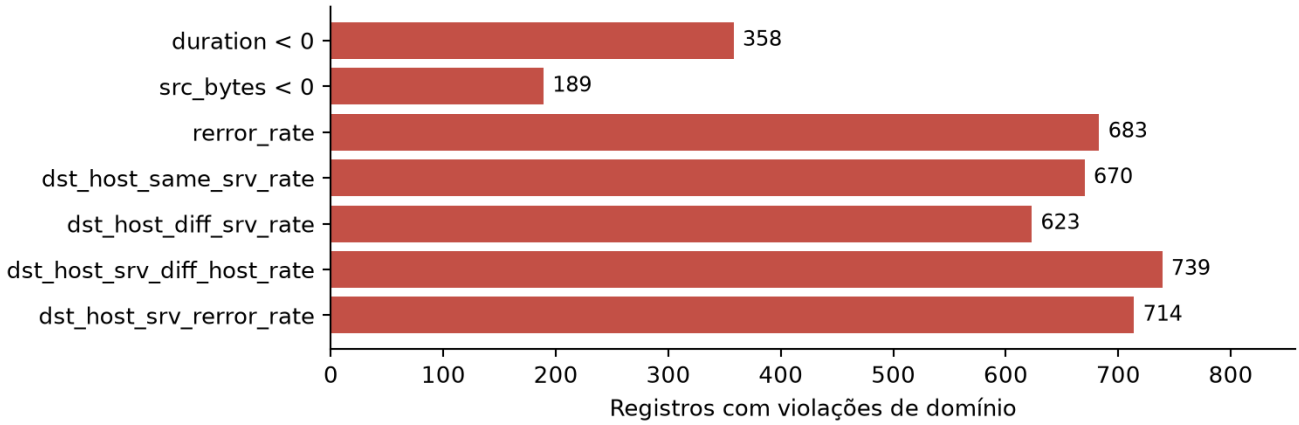



Figura 3. Violações por atributo. Uma linha pode apresentar mais de um problema.

Valores extremos também aparecem nas estatísticas descritivas. Magnitude elevada, isoladamente, não comprova erro: os limites devem ser interpretados conforme o domínio antes de definir o tratamento.

## 6. Informações repetidas e atributo constante

| Atributo | Relação observada |
|---|---|
| src_bytes_kb | src_bytes / 1024 |
| dst_bytes_kb | dst_bytes / 1024 |
| total_bytes | src_bytes + dst_bytes |
| same_srv_pct | same_srv_rate × 100 |

Tabela 2. Relações confirmadas nos registros com os valores necessários disponíveis.

**protocolo_cod** repete o protocolo padronizado: tcp = 0, udp = 1 e icmp = 2. **num_outbound_cmds** é constante, com valor zero em todo o treino. Essas evidências orientam a avaliação de remoção de informações repetidas ou sem variação.

## 7. Duplicatas e conflitos de classe

Há **11.355 duplicatas exatas além da primeira ocorrência (16,26%)**, considerando a classe. Separadamente, foram encontrados **1.702 grupos** com os mesmos 49 atributos e classes diferentes, envolvendo **3.730 linhas**. O agrupamento considera os padrões de ausência. Os conflitos sugerem possível ruído nos rótulos, mas não determinam qual classe está correta. Nenhuma linha foi removida.

# Possíveis vazamentos de dados

## 8. Associação dos atributos com a classe

O notebook apresenta a correlação de todos os atributos numéricos com o alvo binário (anomaly = 1; normal = 0), incluindo sinal, magnitude e número de observações válidas. A correlação da coluna constante é indefinida. Para os atributos textuais, foram examinadas as contagens por classe e as taxas de anomalia por categoria padronizada.

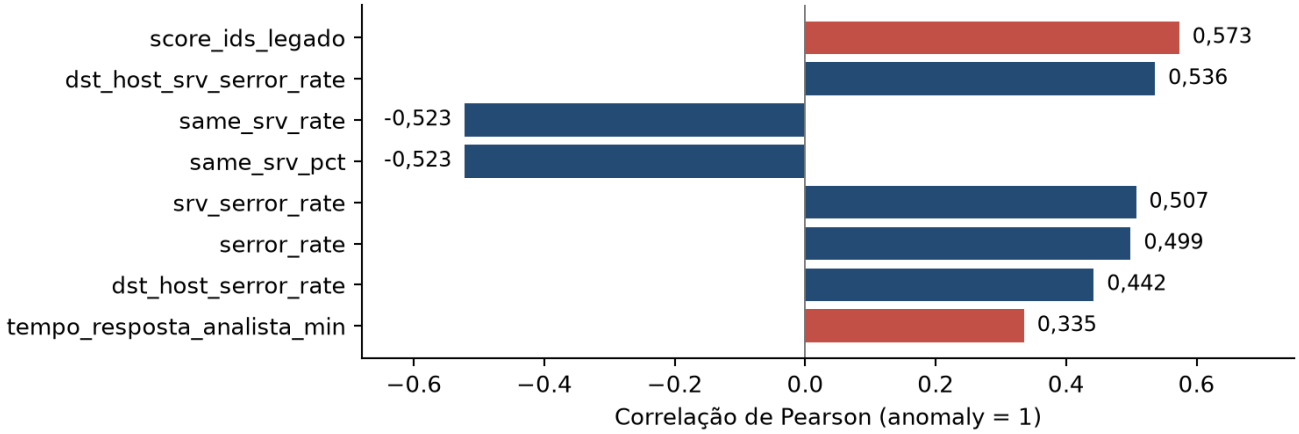



Figura 4. Oito maiores correlações em valor absoluto; o gráfico preserva o sinal.

**score_ids_legado:** correlação de aproximadamente 0,5734. É necessário verificar como o escore foi produzido e se estava disponível antes da previsão.

**tipo_alerta_soc:** ALERTA aparece em 3.379 anomalias e 1.657 conexões normais. A associação é forte, mas o atributo não corresponde exatamente ao rótulo. Sua utilização depende de conhecer quando o alerta é produzido e quais informações utiliza.

**tempo_resposta_analista_min:** está preenchido em aproximadamente 76,5% das anomalias e ausente em 95,6% dos normais. Se registrado após o incidente ou sua classificação, introduzirá informação futura. O padrão de ausência também merece investigação.

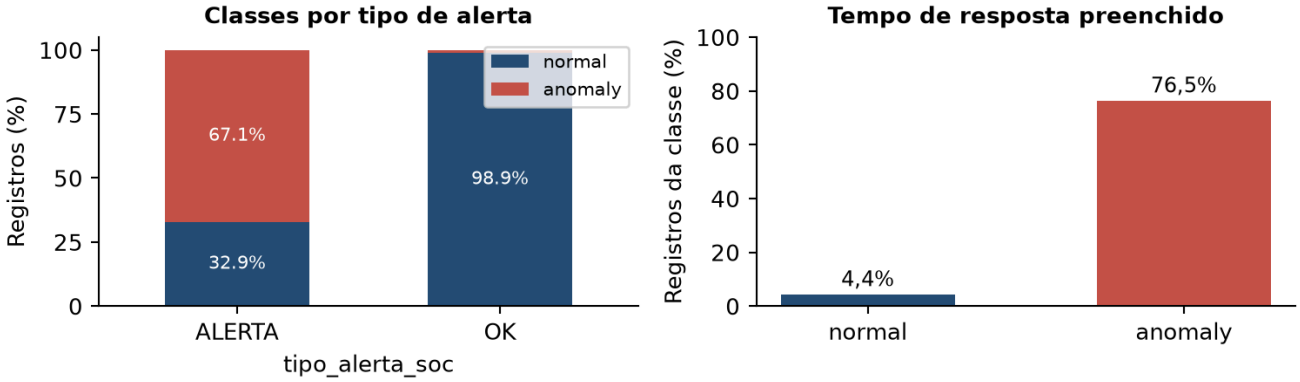



Figura 5. Associação do alerta e do preenchimento do tempo de resposta com a classe.

**Associação estatística não confirma vazamento.** A decisão depende da origem das informações e de sua disponibilidade no momento da previsão. Duplicatas entre futuras partições de treino e validação representam outro risco metodológico.

# Diagnóstico e próximos passos

## 9. Síntese dos resultados

| Problema | Evidência no treino | Encaminhamento para a Etapa 02 |
|---|---|---|
| Desbalanceamento | 94,16% normal; 5,84% anomaly | Comparar balanceamento e avaliar F1 macro e métricas por classe. |
| Formatação e cardinalidade | service: 96 → 67 categorias; protocolos: 6 → 3 | Padronizar texto e comparar a codificação adequada. |
| Valores ausentes | src_bytes: 39,96%; tempo de resposta: 91,37% | Investigar ausências e definir tratamento por atributo. |
| Violações de domínio | Duração e bytes negativos; cinco taxas fora de [0, 1] | Definir tratamento com base no significado dos atributos. |
| Redundância e constante | Quatro fórmulas; protocolo codificado; uma constante | Avaliar remoção das informações repetidas ou sem variação. |
| Duplicatas e conflitos | 11.355 duplicatas; 1.702 grupos conflitantes | Investigar rótulos e evitar exemplos iguais entre partições. |
| Suspeita de vazamento | Atributos operacionais associados à classe | Verificar origem e disponibilidade antes da previsão. |

## 10. Conclusão

A análise exploratória identificou uma base fortemente desbalanceada, com valores ausentes, diferenças de formatação, violações de domínio, informações redundantes, uma coluna constante e registros repetidos ou com classes conflitantes. Esses problemas precisam ser considerados antes do treinamento para que a comparação dos classificadores seja confiável.

Na próxima etapa, serão avaliados os tratamentos dos dados, a codificação, as transformações numéricas, o balanceamento e a redução de dimensionalidade ou seleção de instâncias. A escolha dos tratamentos deverá ser justificada pela interpretação dos atributos e pelos resultados comparativos. Os conflitos de classe exigem cuidado, pois os dados observados não determinam automaticamente o rótulo correto.

As transformações que dependem de estimativas dos dados devem ser ajustadas apenas nas partições de treino da validação. A origem das colunas suspeitas precisa ser esclarecida antes de decidir sobre sua utilização. O arquivo de teste será reservado à aplicação do pipeline final.

Fontes: enunciado do trabalho (docs/enunciado_novo.pdf), treino.csv e notebooks/TrabalhoIA.ipynb. Todas as figuras foram geradas a partir do conjunto de treino.